

# TRABAJO PRÁCTICO INTEGRADOR: ANÁLISIS BIOINFORMÁTICO DEL BROTE DE BRUCELOSIS PORCINA EN ENTRE RÍOS

## Introducción

El presente trabajo tiene como objetivo realizar un análisis bioinformático integral del agente causante de un brote de brucelosis porcina en Entre Ríos.

La brucelosis es una enfermedad zoonótica de importancia tanto en medicina veterinaria como en salud pública, causada por bacterias del género *Brucella* (Revisión bibliográfica en archivo "Revision bibliografica.pdf"). El análisis incluye el procesamiento de secuencias de ADN obtenidas mediante tecnología Sanger y secuenciación masiva Illumina, el ensamblado del genoma, la predicción y anotación de genes, análisis filogenético y el diseño de primers para un kit diagnóstico por PCR.

## Procesamiento y ensamblado de secuencias

### Procesamiento de secuencias Sanger

Las secuencias obtenidas mediante tecnología Sanger se encontraban en formato SCF (Standard Chromatogram Format), el cual almacena tanto la secuencia de bases como los valores de calidad asociados a cada base secuenciada. El procesamiento de estas secuencias se realizó mediante la GUI de prepag4 del paquete de Standen. Se eliminaron virtualmente (soft clipping) las regiones de mala calidad y vector.

El resultado de estos procesos son archivos .exp con el mismo nombre de cada electroferograma y una serie de archivos con listas de electroferogramas que pasaron los diferentes requerimientos de cada módulo. El que es más relevante es pregap.passed ya que será utilizado durante el ensamblado. En este caso, dicho archivo contiene los 242 nombres de archivos, indicando que todas las secuencias procesadas cumplieron con los criterios mínimos de calidad establecidos.



## Análisis de calidad de reads Illumina

Las secuencias cortas obtenidas mediante secuenciación Illumina se encontraban en el archivo Set3.fq en formato FASTQ. Este formato incluye para cada read cuatro líneas: el identificador de la secuencia, la secuencia nucleotídica, un separador, y los valores de calidad codificados en formato ASCII.

Para evaluar la calidad de estas secuencias se utilizó FastQC:

```
fastqc Set3.fq -o /Brucelosis_TP_Integrador/02_pregap4_processing/
```

El análisis de FastQC reveló las siguientes características del conjunto de datos:

- Total de secuencias: 65,000 reads
- Longitud de reads: 150 nucleótidos
- Tipo: Single-end
- Encoding de calidad: Sanger / Illumina 1.9
- Contenido GC promedio: 55%
- Rango de valores de calidad Phred: 35-38

| Measure                           | Value                   |
|-----------------------------------|-------------------------|
| Filename                          | Set3.fq                 |
| File type                         | Conventional base calls |
| Encoding                          | Sanger / Illumina 1.9   |
| Total Sequences                   | 65000                   |
| Total Bases                       | 9.7 Mbp                 |
| Sequences flagged as poor quality | 0                       |
| Sequence length                   | 150                     |
| %GC                               | 55                      |

Fig. 2: Estadísticas básicas obtenidas por FastQC




Fig. 3: Distribución de los valores de calidad a lo largo de la secuencia

Los valores de calidad Phred observados (Q35-Q38) corresponden a una probabilidad de error por base entre 0.001 y 0.0002, lo que se considera de excelente calidad para secuencias Illumina. Esto indica una precisión superior al 99.9% (valor obtenido mediante:  $Q = -10 \log_{10}(p)$ ) en la identificación de bases.

El contenido GC del 55% es consistente con el genoma de *Brucella suis*, cuyo genoma de referencia presenta un contenido GC del 57.2%.

Los gráficos generados por FastQC mostraron una distribución de calidad homogénea a lo largo de toda la longitud de los reads, sin evidencia de degradación significativa de calidad hacia los extremos 3' de las secuencias, lo cual es indicativo de una corrida de secuenciación exitosa. No se detectaron secuencias adaptadoras ni contaminantes, ni tampoco secuencias sobrerrepresentadas que pudieran indicar problemas técnicos o contaminación.

### Ensamblado de secuencias largas (Sanger) mediante Gap4

El ensamblado de secuencias es el proceso mediante el cual múltiples fragmentos de ADN secuenciados se alinean y combinan para reconstruir secuencias continuas más largas, denominadas contigs (contiguous sequences). El ensamblado es particularmente desafiante cuando se trabaja con lecturas relativamente cortas que deben superponerse correctamente para inferir la secuencia completa.

Para el ensamblado de las 242 secuencias Sanger procesadas se utilizó Gap4, un programa del paquete Staden diseñado específicamente para el ensamblado de secuencias generadas por método de Sanger.




Fig. 4: Captura de pantalla de la configuración de gap4

El proceso de ensamblado generó una base de datos Gap4 conteniendo 9 contigs. La interfaz gráfica de Gap4 mostró la lista de contigs resultantes con sus respectivas longitudes y número de secuencias que los componen. Los contigs más relevantes fueron:

- Contig GBUBM92TR (#187): 14,532 bp ensambladas a partir de 126 secuencias
- Contig GBRBC20TF (#22): 4,334 bp a partir de 43 secuencias
- Contig GBRAN41TR (#11): 693 bp a partir de 1 secuencia

| Contig List      |        |             |
|------------------|--------|-------------|
| Name             | Length | # sequences |
| GBUBM92TR (#187) | 14532  | 126         |
| GBRBC20TF (#22)  | 4334   | 43          |
| GBRAN41TR (#11)  | 693    | 1           |
| GBUBA83TR (#167) | 8257   | 67          |
| GBREH88TF (#104) | 474    | 1           |
| GBUAW83TF (#161) | 86     | 1           |
| GBUAZ20TF (#164) | 580    | 1           |
| GBUBE21TF (#173) | 437    | 1           |
| GBUCN09TF (#223) | 850    | 1           |

Fig. 5: Lista de contigs obtenida por gap4




Fig. 6: Representación gráfica los contigs

La longitud total aproximada de todas las secuencias ensambladas fue de 29,981 bp, distribuidas en los 9 contigs mencionados. Este resultado indica una fragmentación considerable del ensamblado, lo cual es esperable dado que las secuencias Sanger tienen una cobertura limitada y no necesariamente cubren de manera continua toda la región genómica de interés.

Los contigs fueron exportados desde Gap4 en formato FASTA mediante la opción de exportación de la interfaz gráfica, generando el archivo sanger\_contigs.fasta:

Este archivo contiene las 9 secuencias consenso resultantes del ensamblado, cada una representando una región genómica contigua reconstruida a partir de las secuencias Sanger superpuestas.

## Ensamblado híbrido con SPAdes

El ensamblado híbrido es una estrategia que combina datos de secuenciación de diferentes tecnologías para aprovechar las ventajas complementarias de cada una. En este caso, se combinaron las secuencias largas y precisas obtenidas por tecnología Sanger (representadas por los 9 contigs previamente ensamblados) con las secuencias cortas pero de alta cobertura obtenidas por tecnología Illumina. Esta aproximación permite utilizar los contigs Sanger como "esqueleto" o guía para el ensamblado, mientras que las lecturas Illumina aportan información para llenar gaps, corregir errores y proporcionar mayor profundidad de cobertura.

Para el ensamblado híbrido se utilizó SPAdes (St. Petersburg genome assembler), versión 3.15.5, un ensamblador de novo ampliamente utilizado para genomas bacterianos.

El comando ejecutado fue:

```
spades.py \  
-s /home/ana/Desktop/Set3.fq \  
--trusted-contigs sanger_contigs.fasta \  
-o hybrid_assembly \  
--threads 4 \  
--memory 16
```

Los parámetros utilizados significan:

- ♦ -s: especifica el archivo de lecturas single-end de Illumina
- ♦ --trusted-contigs: indica las secuencias Sanger como contigs de alta confiabilidad que SPAdes debe incorporar preferentemente en el ensamblado
- ♦ -o: directorio de salida para los resultados
- ♦ --threads: número de procesadores a utilizar (4 cores)
- ♦ --memory: límite de memoria RAM en GB (16 GB)

SPAdes ejecuta internamente múltiples pasos: corrección de errores de las lecturas Illumina, construcción de grafos de De Bruijn con diferentes valores de k-mer (21, 33, 55, 77), y ensamblado final mediante la resolución del grafo. El uso de contigs trusted permite que SPAdes priorice caminos en el grafo que son consistentes con las secuencias Sanger, reduciendo así la fragmentación del ensamblado final.

SPAdes generó múltiples archivos de salida, siendo el más relevante scaffolds.fasta, que contiene las secuencias ensambladas finales.

El análisis del archivo scaffolds.fasta reveló que el ensamblado híbrido produjo un único scaffold de alta calidad:

```
>NODE_1_length_30000_cov_158.511780
```

Este resultado representa una mejora dramática respecto al ensamblado inicial de secuencias Sanger, reduciendo de 9 fragmentos a un único scaffold continuo. Las características del scaffold son:

- ♦ Longitud: 30,000 pares de bases
- ♦ Cobertura promedio: 158.5x
- ♦ Número de scaffolds: 1

La cobertura de 158.5x indica que cada posición nucleotídica del ensamblado está respaldada por un promedio de 158 lecturas independientes, lo cual confiere una alta confiabilidad al consenso. Esta cobertura elevada se debe principalmente a la contribución de las 65,000 lecturas Illumina de 150 bp, que aportan aproximadamente 9.75 Mbp de

secuencia total ( $65,000 \times 150$  bp), que al mapearse sobre un scaffold de 30 kbp resulta en la cobertura observada.

El archivo de estadísticas generado por SPAdes (contigs.paths) confirmó que el ensamblado integró exitosamente información de ambas tecnologías, utilizando los contigs Sanger como puentes para resolver regiones ambiguas del grafo de De Bruijn construido a partir de las lecturas Illumina.

## Análisis estadístico del genoma ensamblado

El análisis de las características composicionales del genoma ensamblado es fundamental para validar la identidad taxonómica del organismo y evaluar la calidad del ensamblado. Las dos métricas principales analizadas fueron el tamaño del ensamblado y el contenido de guanina-citosina (GC%).

Para calcular estas estadísticas se creó un script bash denominado `calculate_genome_stats.sh`

La ejecución del script produjo los siguientes resultados:

Tamaño del genoma ensamblado: 30,000 pares de bases

Composición de bases:

- Adenina (A): 6,420 bases (21.4%)
- Timina (T): 6,900 bases (23.0%)
- Guanina (G): 8,670 bases (28.9%)
- Citosina (C): 8,010 bases (26.7%)

Contenido GC: 55.57%

El tamaño de 30 kbp representa aproximadamente el 0.9% del genoma completo de *Brucella suis*, cuyo tamaño total es de aproximadamente 3.3Mbp distribuidos en dos cromosomas circulares. Este fragmento corresponde probablemente a una región genómica específica que fue el objetivo de la secuenciación dirigida realizada en el contexto del brote epidemiológico.

El contenido GC del 55.57% es consistente con el contenido GC del genoma de referencia de *B. suis* cepa 1330, que es del 57.2%. La diferencia de 1.63 puntos porcentuales (2.85% de variación relativa) está dentro del rango esperado para variaciones regionales en el genoma bacteriano. Es conocido que el contenido GC no es homogéneo a lo largo del genoma, existiendo regiones con mayor o menor contenido GC dependiendo de factores como la densidad génica, la presencia de elementos repetitivos, y la historia evolutiva de cada región. Dado que el fragmento secuenciado representa menos del 1% del genoma total, es razonable encontrar variaciones locales respecto al promedio genómico global.



La relación G+C / A+T es de 1.22, lo que indica un sesgo moderado hacia bases GC, característico de bacterias del género *Brucella* y otros miembros de las Alphaproteobacteria. Este sesgo puede estar relacionado con la estabilidad térmica del ADN, ya que los pares de bases GC forman tres puentes de hidrógeno en comparación con los dos puentes de los pares AT, confiriendo mayor estabilidad a regiones ricas en GC.

## Predicción y anotación de genes

La predicción de genes es el proceso mediante el cual se identifican las regiones codificantes en una secuencia genómica. Existen dos aproximaciones principales: los métodos *ab initio*, que se basan únicamente en señales intrínsecas de la secuencia como codones de inicio y stop, contenido GC, y uso de codones; y los métodos basados en homología, que utilizan comparaciones con bases de datos de genes conocidos.

### Predicción *ab initio* con Glimmer3

Glimmer (Gene Locator and Interpolated Markov ModelER) es un sistema de predicción de genes *ab initio* ampliamente utilizado para genomas bacterianos. Glimmer utiliza modelos de Markov interpolados (ICM) que capturan las propiedades estadísticas de las secuencias codificantes, entrenándose a partir de un conjunto de genes conocidos de un organismo relacionado.

Para la predicción con Glimmer3 se utilizó el programa *tigr-glimmer*. El proceso de predicción requiere primero entrenar un modelo utilizando un genoma de referencia, en este caso *Brucella suis* cepa 1330 (accesión GCF\_000007505.1), descargado de NCBI.

Se creó el siguiente script para automatizar el proceso (*run\_glimmer.sh*)

Los parámetros utilizados en *glimmer3* fueron:

- -o50: permite un solapamiento máximo de 50 bp entre genes predichos
- -g110: longitud mínima de gen de 110 bp
- -t30: threshold de score mínimo de 30 para considerar una predicción válida

El entrenamiento del modelo extrajo 1,027 ORFs del genoma de referencia de *B. suis*, generando 1,185,433 bytes de secuencias de entrenamiento. El modelo ICM construido captura los patrones de uso de codones y contexto nucleotídico característicos de *Brucella suis*.

La ejecución de Glimmer3 sobre el scaffold de 30 kbp produjo los siguientes resultados:  
Genes predichos: 27 ORFs

El archivo *brucella.predict* contiene las coordenadas de cada gen predicho con el siguiente formato:

```
>NODE_1_length_30000_cov_158.511780
```

|          |      |      |    |      |
|----------|------|------|----|------|
| orf00001 | 1221 | 2180 | +3 | 9.53 |
| orf00002 | 2205 | 2615 | +3 | 9.84 |
| orf00003 | 2615 | 2761 | +2 | 1.70 |
| ...      |      |      |    |      |

Donde las columnas representan: identificador del ORF, posición de inicio, posición de fin, frame y strand (+/-), y score de confianza.

La distribución de genes predichos mostró una cobertura genómica de aproximadamente 87%, con genes en ambas hebras del ADN. La densidad génica calculada fue de 0.9 genes/kb, ligeramente inferior al valor esperado para genomas bacterianos (~1 gen/kb), lo cual puede deberse a la presencia de regiones intergénicas más largas o a la configuración conservadora de los parámetros de predicción.

## Predicción mediante pipeline Prokka

Prokka es un pipeline de anotación automática diseñado específicamente para genomas bacterianos. A diferencia de Glimmer, Prokka no solo predice genes sino que también les asigna funciones mediante comparación con múltiples bases de datos de proteínas y dominios funcionales. Prokka integra internamente varias herramientas: Prodigal para predicción inicial de genes, BLASTp para búsqueda de homología, HMMER para búsqueda de dominios, y bases de datos específicas del género cuando están disponibles.

El comando ejecutado fue:

```
prokka \
  --outdir prokka_annotation \
  --prefix brucella_suis \
  --genus Brucella \
  --species suis \
  --strain "hybrid_assembly" \
  --kingdom Bacteria \
  --usegenus \
  --addgenes \
  --locustag BRUC \
  --evaluate 1e-05 \
  --cpus 4 \
  /Brucellosis_TP_Integrador/03_assembly/hybrid_assembly/scaffolds.fasta
```

Los parámetros más relevantes son:

- ♦ --genus Brucella y --species suis: información taxonómica que permite a Prokka utilizar bases de datos específicas del género
- ♦ --usegenus: activa el uso de la base de datos específica de Brucella para mejorar la precisión de las anotaciones
- ♦ --addgenes: añade nombres de genes cuando se identifican por homología

- ♦ --locustag BRUC: prefijo para los identificadores únicos de cada gen (BRUC\_00001, BRUC\_00002, etc.)
- ♦ --evalue 1e-05: valor máximo de e-value para considerar un match de BLAST como significativo

Prokka ejecutó completamente en aproximadamente 3 minutos, generando múltiples archivos de salida en el directorio prokka\_annotation/:

Resultados de Prokka:

- ♦ Contigs analizados: 1
- ♦ Genes (CDS) predichos: 26
- ♦ Bases totales: 30,000 bp

La diferencia de un gen entre Glimmer (27) y Prokka (26) se debe a que Prokka aplica filtros adicionales basados en evidencia de homología. El gen adicional predicho por Glimmer (orf00001) resultó ser de muy corta longitud (51 aminoácidos) y sin homología detectable, siendo probablemente un falso positivo.

Los archivos generados por Prokka incluyen:

- ♦ brucella\_suis.gbk: archivo GenBank con anotación completa
- ♦ brucella\_suis.gff: coordenadas de genes en formato GFF3
- ♦ brucella\_suis.faa: secuencias proteicas
- ♦ brucella\_suis.ffn: secuencias nucleotídicas de genes
- ♦ brucella\_suis.tsv: tabla resumen de genes y funciones

El análisis del archivo TSV reveló que de los 26 genes predichos, 19 pudieron ser anotados con función conocida, mientras que 7 fueron clasificados como proteínas hipotéticas.

Entre los genes con función conocida se identificaron:

Sistema GAD (resistencia a pH ácido):

- ♦ BRUC\_00002 (gadA): Glutamate decarboxylase alpha (EC 4.1.1.15)
- ♦ BRUC\_00003 (gadB): Glutamate decarboxylase beta (EC 4.1.1.15)
- ♦ BRUC\_00004 (gadC): Glutamate/gamma-aminobutyrate antiporter
- ♦ BRUC\_00005 (glsA1): Glutaminase 1 (EC 3.5.1.2)

Defensa contra estrés oxidativo:

- ♦ BRUC\_00016 (oxyR): Hydrogen peroxide-inducible genes activator
- ♦ BRUC\_00017 (katA): Catalase (EC 1.11.1.6)

Metabolismo de nucleótidos:

- ♦ BRUC\_00014 (guaB): Inosine-5'-monophosphate dehydrogenase (EC 1.1.1.205)
- ♦ BRUC\_00023 (guaA): GMP synthase (EC 6.3.5.2)

Otros genes relevantes:

- ♦ BRUC\_00024 (intA): Prophage integrase (indica presencia de elemento móvil)
- ♦ BRUC\_00019 (dsbB): Disulfide bond formation protein B
- ♦ BRUC\_00020 (rsmB): Ribosomal RNA small subunit methyltransferase B

## Comparación Glimmer vs Prokka

La comparación entre ambas metodologías revela diferencias fundamentales en su aproximación:

Glimmer (ab initio):

- Se basa exclusivamente en señales intrínsecas del ADN
- No requiere bases de datos de referencia para la predicción
- Mayor sensibilidad: puede detectar genes sin homólogos conocidos
- Mayor tasa de falsos positivos
- No asigna función a los genes predichos

Prokka (pipeline integrado):

- Combina predicción ab initio (Prodigal) con validación por homología
- Mayor especificidad: filtra falsos positivos mediante evidencia de homología
- Asigna función automáticamente mediante BLASTp y búsqueda de dominios
- Resultados directamente interpretables desde el punto de vista biológico
- Puede perder genes sin homólogos conocidos (genes huérfanos)

Para genomas bacterianos con organismos de referencia cercanos disponibles, como es el caso de *Brucella suis*, Prokka resulta más conveniente y confiable. La anotación funcional automática reduce significativamente el tiempo de análisis y permite la interpretación biológica inmediata de los resultados. La presencia de genes relacionados con virulencia (sistema GAD, catalasa) confirma que el fragmento secuenciado contiene regiones funcionales importantes del genoma de *Brucella*.

## Visualización de la anotación en Artemis

Artemis es un visor y editor de secuencias genómicas desarrollado por el Sanger Institute. Permite la visualización interactiva de anotaciones genómicas, mostrando genes en ambas hebras del ADN, dominios funcionales, y facilitando la navegación y análisis de características genómicas.

Para visualizar la anotación generada por Prokka se utilizó el archivo GenBank:

```
art prokka_annotation/brucella_suis.gff prokka_annotation/brucella_suis.fna
```

Artemis abrió la visualización mostrando el scaffold de 30 kbp con los 26 genes anotados. La interfaz presenta tres paneles principales: el panel superior muestra la secuencia genómica con marcadores de escala, el panel central muestra los genes como flechas de colores indicando su orientación y hebra, y el panel inferior muestra la secuencia nucleotídica y la traducción proteica.

La visualización permitió observar:

- Distribución de genes en ambas hebras (+ y -)
- Regiones codificantes continuas (operones): el sistema GAD (gadA-gadB-gadC) se observa como un cluster de genes consecutivos en la misma hebra
- Genes hipotéticos intercalados entre genes con función conocida
- Densidad génica homogénea a lo largo del scaffold, sin grandes regiones intergénicas

La visualización en Artemis confirmó la calidad de la anotación y permitió identificar visualmente la organización genómica de la región secuenciada.



Fig. 7: Visualización en Artemis

## Refinamiento de la anotación mediante BLAST

Las proteínas hipotéticas identificadas por Prokka requieren análisis adicional para determinar si son proteínas reales conservadas en el género *Brucella* o posibles artefactos de la predicción. Para ello se realizó una búsqueda de homología mediante BLASTp contra el genoma de referencia de *Brucella suis* 1330.

Primero se creó una base de datos BLAST local del proteoma de referencia:

```
makeblastdb \
```

-in

```
/home/ana/Desktop/Brucelosis_TP_Integrador/ncbi_dataset/ncbi_dataset/data/GCF_000007505.1/protein.faa \
```

```
-dbtype prot \
```

```
-out brucella_db
```

Posteriormente se ejecutó BLASTp:

```
blastp \
-query prokka/prokka_annotation/brucella_suis.faa \
-db brucella_db \
-out blast_vs_brucella_completo.txt \
-evalue 1e-05 \
-num_threads 4 \
-outfmt "6 qseqid sseqid pident length qlen slen evalue bitscore"
```

Las proteínas anotadas por Prokka con funcionalidad conocida coincidieron 100% con la búsqueda en BLAST.

Con el fin de evaluar si las proteínas hipotéticas identificadas por Prokka contenían dominios funcionales conocidos, se realizó un análisis con InterProScan:

```
interproscan.sh -i hypothetical_proteins_clean.faa -f tsv -o
interproscan_results.tsv -dp -appl
Pfam,CDD,Gene3D,Coils,Hamap,MobiDBLite,PANTHER,PRINTS,ProSitePatterns,ProSiteProfiles,SFLD,SMART,TIGRFAM
```

El refinamiento mediante BLASTp contra el proteoma de *Brucella suis* 1330 mostró que 6 de las proteínas hipotéticas (85.7%) presentan 100% de identidad y cobertura completa, lo que confirma que son proteínas reales conservadas en el género *Brucella*, aunque de función desconocida.

| Proteína   | Mejor hit               | % Id  | Long. alineada | Conclusión                      |
|------------|-------------------------|-------|----------------|---------------------------------|
| BRUC_00001 | No aparece en BLAST     | —     | —              | Possible falso positivo (51 aa) |
| BRUC_00007 | WP_002966247.1          | 100%  | 54/54          | Conservada                      |
| BRUC_00015 | WP_006191813.1          | 100%  | 357/357        | Conservada                      |
| BRUC_00018 | WP_002969359.1          | 100%  | 57/57          | Conservada                      |
| BRUC_00021 | WP_002966230.1          | 100%  | 151/151        | Conservada                      |
| BRUC_00021 | (2° hit) WP_006071940.1 | 63.9% | 36 aa          | Dominio parcial                 |
| BRUC_00025 | WP_006191822.1          | 100%  | 76/76          | Conservada                      |
| BRUC_00026 | WP_006073479.1          | 100%  | 352/352        | Conservada                      |

Tabla 1: Resultados de BLAST (archivo: blast\_vs\_brucella.txt)

La proteína BRUC\_00001 (51 aa) no presentó ningún homólogo detectable, y por su longitud corta es probablemente un ORF espurio.

El análisis estructural mediante InterProScan no detectó dominios funcionales conocidos (Pfam, TIGRFAM, SMART, ProSite), pero sí identificó regiones intrínsecamente desordenadas en BRUC\_00015 y BRUC\_00026, lo cual es consistente con proteínas pequeñas sin estructura estable.

| Proteína   | Herramienta | Hallazgo                 |
|------------|-------------|--------------------------|
| BRUC_00015 | MobiDBLite  | Región desordenada 26–51 |
| BRUC_00015 | MobiDBLite  | Región desordenada 26–85 |
| BRUC_00026 | MobiDBLite  | Región desordenada 26–56 |

Tabla 2: Resultados de InterProScan (archivo interproscan\_results.tsv)

Estos resultados son típicos de proteínas hipotéticas bacterianas: alrededor del 20–30% de los genes de Brucella no poseen función asignada y carecen de dominios caracterizados.

En conjunto, el refinamiento validó que la mayoría de las proteínas hipotéticas representan genes genuinos, conservados entre especies, aunque sin función anotada.

### Generación de tabla consolidada de genes y funciones

Para integrar los resultados de la anotación de Prokka con el refinamiento por BLAST se creó un script Python (create\_gene\_table.py) que genera una tabla consolidada:

La ejecución del script generó el archivo gene\_annotation\_table.tsv con 26 genes clasificados según su estado de validación:

- ♦ Genes anotados con función conocida: 20 (77%)
- ♦ Proteínas hipotéticas validadas por BLAST: 5 (19%)
- ♦ Proteínas hipotéticas dudosas: 1 (4%)

Esta tabla consolidada proporciona una visión integral de todos los genes predichos, incluyendo información funcional, validación por homología, y clasificación COG cuando está disponible.

| Locus_Tag  | Gene  | Product                                           | Length_bp | EC_Number | COG     | Validation | BLAST_Refinement                      |
|------------|-------|---------------------------------------------------|-----------|-----------|---------|------------|---------------------------------------|
| BRUC_00001 | -     | hypothetical protein                              | 153       | -         | -       | Dubious    | No homologs found                     |
| BRUC_00002 | gadA  | Glutamate decarboxylase alpha                     | 960       | 4.1.1.15  | COG0076 | Annotated  | -                                     |
| BRUC_00003 | gadB  | Glutamate decarboxylase beta                      | 411       | 4.1.1.15  | COG0076 | Annotated  | -                                     |
| BRUC_00004 | gadC  | Glutamate/gamma-aminobutyrate antiporter          | 1281      | -         | COG0531 | Annotated  | -                                     |
| BRUC_00005 | glsA1 | Glutaminase 1                                     | 954       | 3.5.1.2   | COG2066 | Annotated  | -                                     |
| BRUC_00006 | hdeA  | putative acid stress chaperone HdeA               | 345       | -         | -       | Annotated  | -                                     |
| BRUC_00007 | -     | hypothetical protein                              | 165       | -         | -       | Validated  | Conserved in B. suis (WP_002966247.1) |
| BRUC_00008 | pdeB  | putative cyclic di-GMP phosphodiesterase PdeB     | 1593      | 3.1.4.52  | COG4943 | Annotated  | -                                     |
| BRUC_00009 | gcvA  | Glycine cleavage system transcriptional activator | 888       | -         | -       | Annotated  | -                                     |
| BRUC_00010 | algA  | Alginate biosynthesis protein AlgA                | 1416      | -         | COG0662 | Annotated  | -                                     |
| BRUC_00011 | glmM  | Phosphoglucosamine mutase                         | 1434      | 5.4.2.10  | COG1109 | Annotated  | -                                     |
| BRUC_00012 | -     | putative aminopeptidase                           | 1107      | 3.4.11.-  | COG3191 | Annotated  | -                                     |
| BRUC_00013 | clcA  | H(+)/Cl(-) exchange transporter ClcA              | 1356      | -         | COG0038 | Annotated  | -                                     |
| BRUC_00014 | guaB  | Inosine-5'-monophosphate dehydrogenase            | 1494      | 1.1.1.205 | COG0516 | Annotated  | -                                     |
| BRUC_00015 | -     | hypothetical protein                              | 1074      | -         | -       | Validated  | Conserved in B. suis (WP_006191813.1) |
| BRUC_00016 | oxyR  | Hydrogen peroxide-inducible genes activator       | 954       | -         | -       | Annotated  | -                                     |
| BRUC_00017 | katA  | Catalase                                          | 1500      | 1.11.1.6  | -       | Annotated  | -                                     |
| BRUC_00018 | -     | hypothetical protein                              | 174       | -         | -       | Validated  | Conserved in B. suis (WP_002969359.1) |
| BRUC_00019 | dsbB  | Disulfide bond formation protein B                | 627       | -         | -       | Annotated  | -                                     |
| BRUC_00020 | rsmB  | Ribosomal RNA small subunit methyltransferase B   | 1290      | 2.1.1.176 | -       | Annotated  | -                                     |
| BRUC_00021 | -     | hypothetical protein                              | 576       | -         | -       | Partial    | Partial homology (63.9%)              |
| BRUC_00022 | mqnB  | Futalosine hydrolase                              | 633       | 3.2.2.26  | -       | Annotated  | -                                     |
| BRUC_00023 | guaA  | GMP synthase [glutamine-hydrolyzing]              | 1563      | 6.3.5.2   | COG0518 | Annotated  | -                                     |
| BRUC_00024 | intA  | Prophage integrase IntA                           | 1257      | -         | COG0582 | Annotated  | -                                     |
| BRUC_00025 | -     | hypothetical protein                              | 231       | -         | -       | Validated  | Conserved in B. suis (WP_006191822.1) |
| BRUC_00026 | -     | hypothetical protein                              | 1059      | -         | -       | Validated  | Conserved in B. suis (WP_006073479.1) |

Fig. 8: Tabla de genes anotados con Prokka y refinados con BLAST

## Análisis filogenético

El análisis filogenético permite comprender las relaciones evolutivas entre organismos mediante la comparación de secuencias de genes o proteínas conservadas. En el contexto de un brote epidemiológico, el análisis filogenético es crucial para establecer la identidad del agente etiológico y comprender su relación con otras cepas conocidas.

### Selección de proteína y búsqueda de homólogos con PSI-BLAST

Para el análisis filogenético se seleccionó la proteína katA (catalasa, BRUC\_00017) por las siguientes razones: es un gen conservado presente en todas las bacterias aerobias, tiene función conocida relacionada con virulencia, y su longitud es adecuada para análisis filogenético. La catalasa es una enzima que descompone el peróxido de hidrógeno (H<sub>2</sub>O<sub>2</sub>) en agua y oxígeno, y es esencial para que Brucella sobreviva dentro de los macrófagos del hospedador, donde el sistema inmune genera especies reactivas del oxígeno como mecanismo de defensa.

PSI-BLAST (Position-Specific Iterated BLAST) es una variante de BLAST que realiza búsquedas iterativas, mejorando su sensibilidad con cada iteración mediante la construcción de un perfil PSSM (Position-Specific Scoring Matrix). Este perfil captura las posiciones



conservadas y variables de la proteína, permitiendo detectar homólogos más divergentes que no serían identificados con BLAST convencional.

El BLAST convencional (blastp) utiliza una matriz de sustitución estática (típicamente BLOSUM62) que asigna el mismo peso a todas las posiciones de la proteína. En contraste, PSI-BLAST construye un perfil específico de la proteína query después de la primera iteración, dando mayor peso a las posiciones altamente conservadas y menor peso a las posiciones variables. Esto resulta en:

1. Mayor sensibilidad para detectar homólogos divergentes
2. Capacidad para encontrar relaciones evolutivas más distantes
3. Expansión progresiva del conjunto de secuencias homólogas con cada iteración
4. Mejor poder discriminante entre homología real y similitud casual

Para análisis filogenético, donde se busca capturar la mayor diversidad taxonómica posible, PSI-BLAST es superior al BLAST convencional.

La secuencia de katA fue extraída de los resultados de Prokka.

PSI-BLAST se ejecutó mediante la interfaz web de NCBI con los siguientes parámetros:

- Algoritmo: PSI-BLAST
- Base de datos: nr (non-redundant protein database)
- Max target sequences: 100

Se realizaron 3 iteraciones y se seleccionaron 10 secuencias representativas que incluían:

- Diferentes especies de Brucella (B. melitensis, B. abortus, B. canis, B. intermedia, B. pseudogrignensis)
- Géneros relacionados de Alphaproteobacteria (Alphaproteobacteria bacterium, Elsteria sp.)

| select all 100 sequences selected <a href="#">Skip to the first new sequence</a> |                                                                     |                                                    |           |             |             |         |            |          |                                | PSI-BLAST iteration 3               |                                     |             |
|----------------------------------------------------------------------------------|---------------------------------------------------------------------|----------------------------------------------------|-----------|-------------|-------------|---------|------------|----------|--------------------------------|-------------------------------------|-------------------------------------|-------------|
|                                                                                  | Description                                                         | Scientific Name                                    | Max Score | Total Score | Query Cover | E value | Per. Ident | Acc. Len | Accession                      | Select for PSI blast                | Used to build PSSM                  | Newly added |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase [Brucella melitensis bv. 1 str. 16M]</a>       | <a href="#">Brucella melitensis bv. 1 str. 16M</a> | 1052      | 1052        | 100%        | 0.0     | 99.80%     | 507      | <a href="#">AAL54135.1</a>     | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">Catalase [Brucella intermedia LMG 3301]</a>             | <a href="#">Brucella intermedia LMG 3301</a>       | 1051      | 1051        | 100%        | 0.0     | 92.79%     | 519      | <a href="#">EEQ93200.1</a>     | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">MULTISPECIES: catalase KatA [Brucella]</a>              | <a href="#">Brucella</a>                           | 1051      | 1051        | 100%        | 0.0     | 99.80%     | 499      | <a href="#">WP_002966234.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase [Brucella abortus S99]</a>                     | <a href="#">Brucella abortus S99</a>               | 1051      | 1051        | 100%        | 0.0     | 99.80%     | 505      | <a href="#">ERM04788.1</a>     | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">Catalase [Brucella canis HSK A52141]</a>                | <a href="#">Brucella canis HSK A52141</a>          | 1051      | 1051        | 100%        | 0.0     | 100.00%    | 507      | <a href="#">AEW15609.1</a>     | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">MULTISPECIES: catalase KatA [Brucella]</a>              | <a href="#">Brucella</a>                           | 1051      | 1051        | 100%        | 0.0     | 100.00%    | 499      | <a href="#">WP_004690104.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase [Brucella melitensis]</a>                      | <a href="#">Brucella melitensis</a>                | 1051      | 1051        | 100%        | 0.0     | 99.60%     | 499      | <a href="#">ODN39716.1</a>     | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase KatA [Brucella melitensis]</a>                 | <a href="#">Brucella melitensis</a>                | 1050      | 1050        | 100%        | 0.0     | 99.60%     | 499      | <a href="#">WP_277356877.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase [Brucella sp. NF 2653]</a>                     | <a href="#">Brucella sp. NF 2653</a>               | 1050      | 1050        | 100%        | 0.0     | 99.60%     | 507      | <a href="#">EFM63025.1</a>     | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">MULTISPECIES: catalase KatA [Brucella]</a>              | <a href="#">Brucella</a>                           | 1049      | 1049        | 100%        | 0.0     | 99.40%     | 499      | <a href="#">WP_008509943.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase KatA [Brucella intermedia]</a>                 | <a href="#">Brucella intermedia</a>                | 1049      | 1049        | 100%        | 0.0     | 92.99%     | 499      | <a href="#">WP_100652125.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase KatA [Brucella abortus]</a>                    | <a href="#">Brucella abortus</a>                   | 1049      | 1049        | 100%        | 0.0     | 99.60%     | 499      | <a href="#">WP_306315175.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase KatA [Brucella abortus]</a>                    | <a href="#">Brucella abortus</a>                   | 1049      | 1049        | 100%        | 0.0     | 99.60%     | 499      | <a href="#">WP_006116368.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">catalase KatA [Brucella intermedia]</a>                 | <a href="#">Brucella intermedia</a>                | 1049      | 1049        | 100%        | 0.0     | 92.79%     | 499      | <a href="#">WP_230349940.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">MULTISPECIES: catalase KatA [unclassified Brucella]</a> | <a href="#">unclassified Brucella</a>              | 1049      | 1049        | 100%        | 0.0     | 99.60%     | 499      | <a href="#">WP_105985125.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/>                                              | <a href="#">MULTISPECIES: catalase KatA [Brucella]</a>              | <a href="#">Brucella</a>                           | 1049      | 1049        | 100%        | 0.0     | 99.60%     | 499      | <a href="#">WP_008936945.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |

Fig. 9: Captura de pantalla de los resultados obtenidos por la 3ra iteración

Las secuencias fueron descargadas en formato FASTA y guardadas en el archivo katA\_homologs.fasta.

### **Incorporación de la secuencia query al análisis**

Se combinó la secuencia de katA del ensamblado con las secuencias descargadas de PSI-BLAST: `cat katA.faa katA_homologs.fasta > katA_all_sequences.fasta`

Este archivo contiene 11 secuencias totales: la secuencia de katA del ensamblado de Brucella del brote y 10 homólogos de PSI-BLAST.

### **Alineamiento múltiple con ClustalOmega**

El alineamiento múltiple de secuencias (MSA) es el proceso de alinear tres o más secuencias biológicas para identificar regiones de similitud que pueden indicar relaciones funcionales, estructurales o evolutivas. Los algoritmos de alineamiento múltiple buscan maximizar el número de residuos idénticos o similares en columnas verticales, insertando gaps (espacios) cuando es necesario.

Para el alineamiento se utilizó ClustalOmega, una herramienta de alineamiento múltiple que utiliza árboles guía y perfiles HMM para generar alineamientos de alta calidad:

```
clustalo \  
-i katA_all_sequences.fasta \  
-o katA_aligned_complete.fasta \  
--outfmt=fasta \  
--threads=4 \  
--verbose
```

ClustalOmega ejecutó el siguiente proceso:

1. Cálculo de distancias par a par entre todas las secuencias
2. Construcción de un árbol guía mediante clustering jerárquico
3. Alineamiento progresivo siguiendo el orden del árbol guía
4. Refinamiento iterativo del alineamiento

El alineamiento resultante en katA\_aligned\_complete.fasta muestra regiones altamente conservadas intercaladas con regiones más variables.




Fig. 10: Alineamiento visualizado con clustalx

## Análisis de dominios conservados con InterPro

InterPro es una base de datos integrada de familias de proteínas, dominios y sitios funcionales que combina información de múltiples bases de datos especializadas (Pfam, SMART, PANTHER, ProSite, etc.). El análisis de dominios permite identificar regiones funcionales conservadas dentro de proteínas y predecir su función molecular.

Para caracterizar estructural y funcionalmente la proteína BRUC\_00017, anotada como catalasa (kata) por Prokka y con una longitud de 499 aminoácidos, se realizó un análisis exhaustivo utilizando InterProScan. Este servidor integra múltiples bases de datos especializadas (Pfam, SMART, CDD, Gene3D, PANTHER, PRINTS, SUPERFAMILY, entre otras), permitiendo identificar dominios, familias, sitios funcionales y términos GO asociados.

El análisis detectó siete entradas de InterPro que coinciden claramente con proteínas catalasas mono-funcionales dependientes de hemo, una clase de enzimas altamente conservadas en bacterias aerobias y esenciales para la detoxificación de peróxido de hidrógeno (H<sub>2</sub>O<sub>2</sub>).

InterPro asignó BRUC\_00017 a varias familias relacionadas con la superfamilia de catalasas, incluyendo:

- Catalase – mono-functional, haem-containing (IPR018028): Incluye catalasas típicas que utilizan un grupo hemo como cofactor catalítico. Confirma que esta proteína pertenece a la familia clásica de catalasas bacterianas.
- Catalase, clades 1 and 3 (IPR024711): La clasificación en clados identifica relaciones evolutivas dentro de la superfamilia. Las catalasas del clado 3 son comunes en proteobacterias y tienen características estructurales específicas, como arquitectura tetramérica estable.
- Catalase, clade 3 (IPR040333): Específicamente asigna a BRUC\_00017 al clado 3, lo cual es consistente con catalasas bacterianas altamente conservadas involucradas en virulencia y resistencia a estrés oxidativo.

Esta multiplicidad de asignaciones coherentes refuerza la precisión funcional de la anotación.

InterPro detectó también varios dominios estructurales dentro de la secuencia:

- ♦ Catalase\_core (IPR011614, PF00199, SMART: Catalase\_2): Dominio catalítico principal de las catalasas. Comprende gran parte del cuerpo de la proteína y es responsable de la actividad enzimática.
- ♦ Catalase superfamily (SSF56634): Modelo estructural basado en SUPERFAMILY que confirma que la proteína tiene el plegamiento típico de catalasas dependientes de hemo.
- ♦ Catalase-related immune-responsive domain (Detectado por Pfam como Catalase-rel, subfamilia asociada a respuestas celulares frente a estrés oxidativo). Sugiere que esta proteína contribuye activamente a la protección frente a especies reactivas del oxígeno.

InterPro asigna los siguientes Gene Ontology (GO):

- ♦ Biological Process (BP)
  - ♦ GO:0006979 – response to oxidative stress
  - ♦ GO:0042744 – hydrogen peroxide catabolic processAmbos procesos describen el rol de katA en la detoxificación de ROS (Reactive Oxygen Species).
- ♦ Molecular Function (MF)
  - ♦ GO:0004096 – catalase activity
  - ♦ GO:0020037 – heme bindingDescriben la función bioquímica central de la enzima.
- ♦ Cellular Component (CC)
  - ♦ InterPro: None
  - ♦ PANTHER: cytoplasm (GO:0005737)(las catalasas bacterianas suelen ser citoplasmáticas)

El análisis InterProScan proporciona una validación sólida y multifacética de que BRUC\_00017 corresponde a katA, una catalasa bacteriana altamente conservada, esencial para la supervivencia frente a estrés oxidativo. La presencia de dominios completos, sitios activos clásicos y términos GO consistentes refuerza su anotación y sirve como excelente base para el alineamiento múltiple, el logo de secuencia y el análisis filogenético posterior.




Fig. 11: Visualización del resultado de búsqueda con InterPro

| InterPro GO terms                                                                                                                                                                          |                                                                                                                                                         |                                                                                            |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| Biological Process                                                                                                                                                                         | Molecular Function                                                                                                                                      | Cellular Component                                                                         |
| <ul style="list-style-type: none"> <li>response to oxidative stress (GO:0006979) <a href="#">↗</a></li> <li>hydrogen peroxide catabolic process (GO:0042744) <a href="#">↗</a></li> </ul>  | <ul style="list-style-type: none"> <li>catalase activity (GO:0004096) <a href="#">↗</a></li> <li>heme binding (GO:0020037) <a href="#">↗</a></li> </ul> | <p>None</p>                                                                                |
| PANTHER GO terms                                                                                                                                                                           |                                                                                                                                                         |                                                                                            |
| Biological Process                                                                                                                                                                         | Molecular Function                                                                                                                                      | Cellular Component                                                                         |
| <ul style="list-style-type: none"> <li>response to hydrogen peroxide (GO:0042542) <a href="#">↗</a></li> <li>hydrogen peroxide catabolic process (GO:0042744) <a href="#">↗</a></li> </ul> | <ul style="list-style-type: none"> <li>catalase activity (GO:0004096) <a href="#">↗</a></li> <li>heme binding (GO:0020037) <a href="#">↗</a></li> </ul> | <ul style="list-style-type: none"> <li>cytoplasm (GO:0005737) <a href="#">↗</a></li> </ul> |

Fig. 12: GO terms obtenidos por InterPro y PANTHER

## Generación de logo de secuencia con WebLogo

Un logo de secuencia es una representación gráfica de un alineamiento múltiple que muestra la conservación de cada posición mediante la altura de las letras. Las posiciones altamente conservadas muestran letras grandes, mientras que las posiciones variables muestran múltiples letras pequeñas.

El alineamiento completo de katA fue enviado a WebLogo (<http://weblogo.threeplusone.com/create.cgi>).



El WebLogo generado a partir del alineamiento múltiple de katA (499 aa) muestra una conservación prácticamente completa a lo largo de la región analizada. Esto coincide con los resultados de InterPro, que anotan un dominio de catalasa que abarca la mayor parte de la secuencia y sitios catalíticos (heme binding, ACT\_SITE). La conservación generalizada indica una fuerte presión selectiva para mantener la función catalasa en Brucella y taxones relacionados.

La alta conservación implica que katA tiene pocos sitios informativos para discriminar relaciones recientes entre cepas (baja resolución filogenética para estudios de microevolución).

### Construcción del árbol filogenético con FastTree

Los árboles filogenéticos son representaciones gráficas de las relaciones evolutivas entre organismos o secuencias. FastTree implementa un algoritmo de máxima verosimilitud aproximado optimizado para grandes conjuntos de datos. Para este análisis se ejecutó:

```
FastTree katA_aligned_complete.fasta > katA_tree_complete.nwk
```

El archivo resultante katA\_tree\_complete.nwk contiene el árbol en formato Newick, un formato estándar basado en texto que representa la topología del árbol y las longitudes de ramas mediante paréntesis anidados.



Fig. 14: Visualización del árbol filogenético con FigTree



La posición de la muestra del brote BRUC\_00017 forma un clado monofilético con alta confianza (bootstrap: 0.927) junto a: WP\_004690104.1 (MULTISPECIES: *Brucella*) y AEW15609.1 (*Brucella canis* HSK A52141). La distancia genética entre estas secuencias es prácticamente nula (0.0), indicando alta similitud genética

Se realizó un segundo árbol para evaluar la filogenia con otras familias fuera del género *Brucella*.

Your results are filtered to match records that exclude: *Brucella* (taxid:234) Reset

10 sequences selected sequences newly added this iteration [GenPept](#) [Graphics](#) [Distance tree of results](#) [Multiple alignment](#) [MSA Viewer](#)

Sequences with E-value BETTER than threshold

☐ select all 10 sequences selected [Skip to the first new sequence](#) PSI-BLAST iteration 3

|                                     | Description                                                            | Scientific Name                      | Max Score | Total Score | Query Cover | E value | Per. Ident | Acc. Len | Accession                | Select for PSI blast                | Used to build PSSM                  | Newly added |
|-------------------------------------|------------------------------------------------------------------------|--------------------------------------|-----------|-------------|-------------|---------|------------|----------|--------------------------|-------------------------------------|-------------------------------------|-------------|
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Alivibrio fischeri ES114]                      | <a href="#">Alivibrio fische...</a>  | 855       | 855         | 95%         | 0.0     | 59.03%     | 482      | <a href="#">Q68146.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Staphylococcus aureus subsp. aureus USA300]    | <a href="#">Staphylococcu...</a>     | 855       | 855         | 99%         | 0.0     | 53.82%     | 505      | <a href="#">Q2FH99.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Proteus mirabilis]                             | <a href="#">Proteus mirabilis</a>    | 855       | 855         | 97%         | 0.0     | 60.08%     | 484      | <a href="#">P42321.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Staphylococcus aureus subsp. aureus MRSA252]   | <a href="#">Staphylococcu...</a>     | 853       | 853         | 99%         | 0.0     | 53.61%     | 505      | <a href="#">Q6GH72.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Haemophilus influenzae Rd KW20]                | <a href="#">Haemophilus i...</a>     | 852       | 852         | 95%         | 0.0     | 61.39%     | 508      | <a href="#">P44390.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Bordetella pertussis Tohama I]                 | <a href="#">Bordetella pert...</a>   | 852       | 852         | 95%         | 0.0     | 64.78%     | 482      | <a href="#">P0A323.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Glandirana rugosa]                             | <a href="#">Glandirana rug...</a>    | 852       | 852         | 99%         | 0.0     | 48.61%     | 528      | <a href="#">Q9PWF7.3</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Staphylococcus aureus]                         | <a href="#">Staphylococcu...</a>     | 851       | 851         | 99%         | 0.0     | 53.82%     | 505      | <a href="#">Q9L4S1.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Nitratidessus vibrio vulgaris str. Miyazaki F] | <a href="#">Nitratidessulfovi...</a> | 851       | 851         | 95%         | 0.0     | 58.91%     | 480      | <a href="#">Q9ZNV9.2</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input checked="" type="checkbox"/> | RecName: Full=Catalase [Staphylococcus epidermidis RP62A]              | <a href="#">Staphylococcu...</a>     | 849       | 849         | 99%         | 0.0     | 53.82%     | 504      | <a href="#">Q5HPK8.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input type="checkbox"/>            | RecName: Full=Catalase [Staphylococcus warneri]                        | <a href="#">Staphylococcu...</a>     | 849       | 849         | 99%         | 0.0     | 54.22%     | 505      | <a href="#">Q9KW19.1</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |
| <input type="checkbox"/>            | RecName: Full=Catalase [Cavia porcellus]                               | <a href="#">Cavia porcellus</a>      | 848       | 848         | 96%         | 0.0     | 49.69%     | 527      | <a href="#">Q64405.4</a> | <input checked="" type="checkbox"/> | <input checked="" type="checkbox"/> |             |

Fig. 15: PSI-BLAST de 3 iteraciones con SwissProt excluyendo el género *Brucella*




Fig. 16: Alineamiento con ClustalX de KatA con los 10 primeros hits de PSI-BLAST






Fig. 17: Árbol filogenético visualizado con FigTree

Se observa que la catalasa de *Brucella suis* (BRUC\_00017) se agrupa con otras proteobacterias gamma (*Proteus*, *Bordetella*), lo cual tiene sentido taxonómicamente.

La alta divergencia observada con con Q9PWF7.3 (rana) es anómala. Considero que posibles motivos pueden ser algún error en la base de datos de secuencias, convergencia evolutiva o transferencia horizontal de genes (aunque poco probable en eucariotas).

El grupo *Staphylococcus* muestra una conservación extrema de KatA, reflejando presión selectiva fuerte (el estrés oxidativo es crítico para patógenos).

## Diseño de primers para un kit diagnóstico por PCR

La reacción en cadena de la polimerasa (PCR) es una técnica molecular fundamental que permite amplificar exponencialmente fragmentos específicos de ADN. El diseño de primers (cebadores u oligonucleótidos iniciadores) es crítico para el éxito de la PCR. Los primers son secuencias cortas de ADN monocatenario (típicamente 18-25 nucleótidos) que se unen específicamente a regiones complementarias del ADN molde, definiendo el inicio y el fin del fragmento que será amplificado.

## Desarrollo del script Perl para diseño automático de primers

Para automatizar el diseño de primers para todos los genes predichos se desarrolló un script en lenguaje Perl utilizando los módulos BioPerl Bio::SeqIO y Bio::Tools::GFF. Perl fue seleccionado siguiendo las especificaciones del trabajo práctico, y BioPerl proporciona herramientas robustas para manipulación de secuencias biológicas.

El script design\_primers.pl implementa el siguiente algoritmo:

1. Lee el genoma ensamblado en formato FASTA
2. Lee las anotaciones de genes desde el archivo GFF3 generado por Prokka
3. Para cada gen:
  - Extrae las coordenadas (inicio, fin, hebra)
  - Diseña el primer forward 5 nucleótidos antes del inicio del gen
  - Diseña el primer reverse 5 nucleótidos después del fin del gen
  - Considera la orientación de la hebra para calcular complementos reversos cuando sea necesario
  - Calcula la temperatura de melting ( $T_m$ ) usando la fórmula:  $T_m = 4(G+C) + 2(A+T)$
  - Calcula la temperatura de annealing ( $T_a$ ) como  $T_m - 5^{\circ}\text{C}$
  - Extrae la secuencia del producto de PCR esperado

### Explicación de los pasos clave del algoritmo:

Manejo de hebras: Los genes pueden estar codificados en la hebra positiva (+) o negativa (-) del ADN. Para genes en hebra positiva, el primer forward se toma directamente de la secuencia genómica, mientras que el primer reverse debe ser el complemento reverso de la secuencia downstream. Para genes en hebra negativa, ambos primers requieren transformaciones de complemento reverso debido a que las coordenadas en el GFF están en el sistema de referencia de la hebra positiva.

Cálculo de  $T_m$ : La fórmula  $T_m = 4(G+C) + 2(A+T)$  es una aproximación simple pero efectiva para primers cortos ( $\leq 25$  nt). Esta fórmula refleja el hecho de que los pares GC forman tres puentes de hidrógeno mientras que los pares AT forman solo dos, resultando en mayor estabilidad térmica para secuencias ricas en GC.

Temperatura de annealing: La  $T_a$  se calcula como  $T_m - 5^{\circ}\text{C}$ , lo cual es una regla empírica estándar que proporciona un margen de seguridad para asegurar la especificidad del annealing. Temperaturas de annealing demasiado bajas resultan en amplificación inespecífica, mientras que temperaturas demasiado altas pueden prevenir el annealing completamente.

El script fue ejecutado con el siguiente comando:

```
perl design_primers.pl \  
../03_assembly/hybrid_assembly/scaffolds.fasta \  

```

../04\_gene\_prediction/prokka/prokka\_annotation/brucella\_suis.gff

## Resultados del diseño de primers

El script procesó exitosamente los 26 genes predichos, generando dos archivos de salida:

- ♦ res\_primers.tab: Tabla tabulada con información completa de cada par de primers
- ♦ res\_prod.fa: Archivo multiFASTA con las secuencias de los productos de PCR esperados

Se generó un script con Python para analizar los resultados obtenidos (evaluar\_primers.py), considerando los siguientes criterios:

- Diferencia de temperatura de melting ( $\Delta T_m$ )
- Contenido GC
- Presencia de runs (>4 nt iguales)
- Riesgo de dímeros de primers
- Longitud del amplicón
- Penalizaciones por amplicones demasiado largos (>1000 bp)
- Penalizaciones por  $\Delta T_m > 5^\circ\text{C}$
- Penalización por GC fuera del rango 40–60%

Cada uno de estos factores contribuyó a un score global, cuya máxima puntuación posible era 100. Este enfoque permitió comparar objetivamente todos los genes y determinar cuál de ellos presenta las mejores propiedades experimentales para un ensayo de PCR.

Los resultados del análisis se muestran en la siguiente tabla:

| Gen               | Score      | Amplicón (bp) | $\Delta T_m$ ( $^\circ\text{C}$ ) |
|-------------------|------------|---------------|-----------------------------------|
| <b>BRUC_00018</b> | <b>100</b> | <b>184</b>    | <b>2.0</b>                        |
| BRUC_00001        | 55         | 163           | 8.0                               |
| BRUC_00021        | 55         | 586           | 4.0                               |
| BRUC_00005        | 50         | 964           | 4.0                               |
| BRUC_00007        | 50         | 175           | 10.0                              |
| BRUC_00009        | 50         | 898           | 10.0                              |
| BRUC_00022        | 45         | 643           | 6.0                               |
| BRUC_00006        | 40         | 355           | 4.0                               |
| BRUC_00012        | 40         | 1117          | 2.0                               |

|            |     |      |      |
|------------|-----|------|------|
| BRUC_00013 | 40  | 1366 | 0.0  |
| BRUC_00015 | 40  | 1084 | 0.0  |
| BRUC_00026 | 40  | 1069 | 0.0  |
| BRUC_00003 | 35  | 421  | 8.0  |
| BRUC_00025 | 35  | 241  | 8.0  |
| BRUC_00010 | 25  | 1426 | 2.0  |
| BRUC_00011 | 25  | 1444 | 2.0  |
| BRUC_00016 | 25  | 964  | 6.0  |
| BRUC_00019 | 25  | 637  | 10.0 |
| BRUC_00002 | 20  | 970  | 14.0 |
| BRUC_00014 | 15  | 1504 | 6.0  |
| BRUC_00017 | 15  | 1510 | 6.0  |
| BRUC_00008 | 0   | 1603 | 4.0  |
| BRUC_00020 | 0   | 1300 | 6.0  |
| BRUC_00023 | 0   | 1573 | 6.0  |
| BRUC_00024 | 0   | 1267 | 8.0  |
| BRUC_00004 | -15 | 1291 | 6.0  |

El análisis revela diferencias marcadas entre los pares de primers diseñados para cada gen. En general, muchos genes presentan amplicones demasiado extensos (habitualmente > 1000 bp), lo cual no es apropiado para un kit diagnóstico, ya que los productos largos reducen la eficiencia de amplificación y dificultan la detección en PCR convencional e incluso en qPCR. Asimismo, varios pares de primers presentan  $\Delta T_m$  muy elevados (> 10°C), indicando que los primers no podrían hibridar simultáneamente bajo una misma temperatura de alineamiento, lo cual comprometería gravemente el rendimiento de la reacción.

En contraste, solo un gen cumplió con todos los criterios de diseño sin recibir ninguna penalización: BRUC\_00018. Este gen obtuvo un score perfecto (100/100) y mostró las siguientes características ideales:

- Amplicón corto y fácilmente amplificable (184 bp)
- $\Delta T_m$  muy bajo (2°C)

- Contenido GC dentro del rango óptimo (40–60%)
- Ausencia de runs extensos o secuencias problemáticas
- Sin señales de dímeros entre primers
- Longitud de amplicón compatible con PCR diagnóstica rápida

Estas propiedades hacen que BRUC\_00018 destaque marcadamente por encima del resto, ya que combina eficiencia, sensibilidad, especificidad y robustez en un formato típicamente requerido para kits diagnósticos.

## Conclusiones generales

El presente trabajo permitió realizar un análisis bioinformático integral del agente responsable del brote de brucelosis porcina en Entre Ríos, articulando herramientas de ensamblado, anotación genómica, análisis filogenético y diseño racional de herramientas diagnósticas. A partir de datos de secuenciación Illumina y el procesamiento posterior, se obtuvo un ensamblado robusto que permitió identificar un total de 26 genes, entre los cuales se encuentran proteínas conservadas y factores asociados a funciones metabólicas y de supervivencia bacteriana. El contenido GC obtenido y la comparación con secuencias de referencia respaldaron la asignación taxonómica a *Brucella suis*.

La anotación funcional, refinada mediante búsquedas de homología por BLAST y la evaluación de dominios conservados con InterProScan, permitió distinguir genes con funciones definidas de aquellos anotados como hipotéticos. El análisis detallado de la catalasa *katA*, seleccionado para el estudio filogenético, confirmó tanto su conservación estructural como su rol clave en la respuesta al estrés oxidativo. El alineamiento múltiple y el árbol filogenético generados evidenciaron una clara afinidad evolutiva con cepas de *Brucella suis* y otras especies del género, corroborando la identidad y relación filogenética del aislado bajo estudio.

Finalmente, se desarrolló e implementó un script en Perl para el diseño automático de primers para los 26 genes predichos, seguido de una evaluación computacional exhaustiva en Python que integró parámetros fisicoquímicos, estructurales y técnicos relevantes para PCR diagnóstica. Este análisis permitió identificar al gen BRUC\_00018 como la mejor opción para el desarrollo de un kit de detección, dado que sus primers presentan un  $\Delta T_m$  óptimo, ausencia de artefactos estructurales y un amplicón de 184 bp, ideal para una amplificación sensible y específica.

En conjunto, este trabajo demuestra cómo el análisis bioinformático aplicado a datos genómicos puede aportar evidencia sólida para la caracterización molecular de patógenos y el diseño de herramientas diagnósticas esenciales en el contexto de brotes infecciosos. La integración de ensamblado, anotación, filogenia y diseño de primers permitió no solo caracterizar al agente etiológico, sino también sentar las bases para el desarrollo de un método de detección preciso y basado en fundamentos moleculares robustos.